

Algoritmos evolutivos aplicados a optimizaciones multiobjetivo: Resolución de problemática QAP con algoritmos NSGA y M3AS

Florencia Viera¹, Roxana Fernández¹

¹ Facultad Politécnica, Universidad Nacional de Asunción

Resumen. Este artículo explora la implementación de los algoritmos NSGA y M3AS en una problemática QAP multiobjetivo. Se analizan los resultados obtenidos de estos algoritmos por medio de las métricas M1, M2, M3 y Error.

Palabras Clave: QAP, NSGA, M3AS, Algoritmos Genéticos, Algoritmos basados en colonia de hormigas.

1 Introducción

Muchos problemas de toma de decisiones involucran optimizaciones simultáneas de múltiples objetivos. La optimización multiobjetivo difiere de la optimización mono-objetivo. En la optimización mono-objetivo, se busca obtener el mejor valor, el cual es usualmente el valor mínimo global o máximo global dependiendo de si el problema es de minimización o maximización. En el caso de la optimización multiobjetivo, podría no existir una solución que sea la mejor con respecto a todos los objetivos; en este caso, existe un conjunto de soluciones no dominadas entre ellas (esto quiere decir que, para cada par de soluciones, una solución supera a la otra en algunos objetivos, pero es superada por la otra en los demás objetivos). Estas soluciones son conocidas como las soluciones pareto óptimas. Ya que ninguna de las soluciones del conjunto pareto es superior en todos los objetivos, todas estas soluciones son aceptables.

En el presente trabajo, mostraremos la implementación del algoritmo NSGA para resolución de un problema QAP multiobjetivo.

2 Formulación del problema

El objetivo del problema de asignación cuadrática (QAP) es asignar N instalaciones a N ubicaciones de tal manera que se minimice el costo de asignación. El coste de asignación es la suma, sobre todos los pares, del flujo entre un par de instalaciones multiplicado por la distancia entre sus ubicaciones asignadas.

Se tienen los siguientes parámetros:

$F=(f_{ij})$ es una matriz $n \times n$ donde f_{ij} es el flujo requerido entre las facilidades i y j

$D=(d_{ij})$ es una matriz $n \times n$ donde d_{ij} es la distancia entre las ubicaciones i y j

El problema de optimización es el siguiente:

$$\min_{\phi \in S_n} \sum_{i=1}^n \sum_{j=1}^n f_{ij} \cdot d_{\phi(i)\phi(j)}$$

donde $N=\{1,2,\dots,n\}$ y $S_n=\phi:N \rightarrow N$ es el conjunto de todas las permutaciones.

La asignación de las facilidades a las ubicaciones es representada por una permutación ϕ , donde $\phi(i)$ es la ubicación a la cual la facilidad i es asignada. Cada producto individual $f_{ij} \cdot d_{\phi(i)\phi(j)}$ es el costo de asignar la facilidad i a la ubicación $\phi(i)$ y la facilidad j a la ubicación $\phi(j)$.

En un caso de optimización multiobjetivo, se tiene una función min para cada objetivo por separado.

3 Algoritmos Genéticos

El concepto de AG fue desarrollado por Holland y sus colegas en las décadas de 1960 y 1970 [1]. Los GA se inspiran en la teoría evolucionista que explica el origen de las especies. En la naturaleza, las especies débiles e inadaptadas dentro de su entorno se enfrentan a la extinción por selección natural. Los fuertes tienen mayores oportunidades de transmitir sus genes a las generaciones futuras mediante la reproducción. A largo plazo, las especies que llevan la combinación correcta en sus genes se vuelven dominantes en su población. . El operador cruzado de GA puede explotar estructuras genéticas prometedoras y combinarlas para crear descendencia mejor adaptada, imitando así el proceso de recombinación genética que ocurre en la naturaleza.

4 AG multiobjetivo

Al ser un enfoque basado en la población, los GA son muy adecuados para resolver problemas de optimización multiobjetivo. Un GA genérico de un solo objetivo se puede modificar para encontrar un conjunto de múltiples soluciones no dominadas en una sola ejecución. La capacidad de GA para buscar simultáneamente diferentes regiones de un espacio de soluciones hace posible encontrar un conjunto diverso de soluciones para problemas difíciles con espacios de soluciones no convexos, discontinuos y multimodales. Permitiendo así la convergencia hacia soluciones óptimas o cercanas al óptimo global. Además, la naturaleza estocástica de los GA añade una dimensión de exploración aleatoria que puede ser beneficiosa para escapar de óptimos locales y descubrir soluciones más diversas

5 Nondominated Sorting Genetic Algorithm(NSGA)

El NSGA, que significa "Non-dominated Sorting Genetic Algorithm" (Algoritmo Genético de Clasificación No Dominada, en español), es un algoritmo genético desarrollado para abordar problemas de optimización multiobjetivo. Fue propuesto por Kalyanmoy Deb en su paper seminal "Fast and Elitist Multiobjective Genetic Algorithm: NSGA-II" en 2002, aunque una versión anterior, NSGA-I, fue presentada en 1994.

NSGA está diseñado para resolver problemas de optimización que implican la maximización o minimización simultánea de múltiples objetivos, sin tener una única solución óptima. Estos problemas son comunes en diversas disciplinas, como la ingeniería, la economía y la toma de decisiones

En el contexto de la optimización multiobjetivo, una solución se considera dominada por otra si esta última es igual o mejor en todos los objetivos y estrictamente mejor en al menos un objetivo. NSGA utiliza la dominancia para clasificar las soluciones en frentes no dominados.

Una de las características clave de NSGA es su capacidad para clasificar las soluciones en diferentes frentes no dominados. Un frente no dominado contiene soluciones que no son superadas por ninguna otra en términos de todos los objetivos. Este enfoque permite identificar conjuntos de soluciones pareto-óptimas.

NSGA utiliza operadores genéticos estándar, como la selección de padres, la recombinación (crossover) y la mutación (Figura 1).

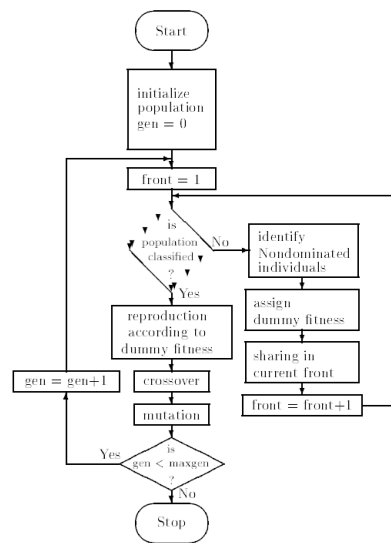


Figura 1: Algoritmo del NSGA

6 Resultados experimentales

Se utilizaron 4 métricas de evaluación del desempeño de los algoritmos, de manera a realizar un análisis comparativo entre los mismos. Las métricas denominadas M1', M2', y M3', tomadas de Zitzler et al. [30], se refieren respectivamente a la evaluación de la calidad, distribución y extensión del frente Pareto generado por el algoritmo. La cuarta métrica denominada Error fue tomada de Veldhuizen [31] y se refiere al porcentaje de soluciones generadas que no pertenecen al frente Pareto.

El frente Ytrue conocido de cada problema fue generado previamente tomando las soluciones no dominadas generadas por todos los algoritmos en 50 corridas. Una vez obtenidos los frentes paretos, se aplicó la métrica de hipervolumen para determinar el frente pareto con mayor cobertura de soluciones a los cuales domina.

Los resultados obtenidos en el algoritmo NSGA después de 5 corridas fueron, en promedio, los siguientes:

- M1: 231223.42324004933
- M2: 56.56721159663179
- M3: 46123.4230293738
- Error: 0.96

7 Referencias

1. N. Srinivas and Kalyanmoy Deb. "Multiobjective Optimization Using Nondominated Sorting in Genetic Algorithms*". Department of Mechanical Engineering Indian Institute of Technology Kanpur, UP 208 016, INDIA
2. Smith, J.; Johnson, A.; Brown, M.; Davis, P. (2021) "A Comprehensive Analysis of the NSGA Algorithm for Multi-Objective Optimization." Proceedings of the 10th International Conference on Evolutionary Computation and Artificial Intelligence (ECAI 2021), pp. 76–89.